Clasificación de mensajes - Cauce

Para Laura Benítez
Andruszyszyn Emanuel - Quirós Juan
14 de octubre de 2026

Problema y propuesta

Cauce recibe unos 6.500 mensajes diarios y nueve personas los derivan. Un destino incorrecto demora la atención; en fraude puede impedir que se frene una operación sospechosa. Comparamos Naive Bayes con KNN para predecir el equipo a partir del texto.

La regla prioriza fraude si su probabilidad alcanza 0,10, automatiza los otros destinos con confianza de al menos 0,60 y envía el resto a revisión. Los textos con menos de dos palabras siempre requieren revisión. Conservamos los parámetros del Sprint 2 y los umbrales del Sprint 3.

Resultados descriptivos en prueba

Ambos modelos y la mesa se comparan sobre 1.586 mensajes aptos, incluidos 176 fraudes reales. Esta prueba ya se había consultado para elegir KNN en Sprint 3.

Indicador	Naive Bayes	KNN	Mesa
Accuracy	93,88%	92,81%	83,54%
F1 macro	0,9346	0,9260	0,8237
Cobertura	99,50%	96,15%	100,00%
Exactitud de derivación	94,17%	92,66%	83,54%
Fraude perdido	5,11%	3,41%	33,52%
Fraudes mal derivados	9	6	59
Falsas alertas de fraude	16	75	42
Errores automáticos totales	92	112	261
Revisiones	8	61	0

Accuracy y F1 miden clases predichas. Cobertura divide por todos los mensajes; exactitud, por los automáticos; fraude perdido, por los fraudes reales. La mesa tiene destinos manuales ya realizados: su cobertura no significa automatización. Revisión no cuenta como fraude perdido.

Recomendamos provisionalmente Naive Bayes bajo el supuesto de reducir errores generales y carga operativa. KNN pierde 3 fraudes menos, pero suma 59 alertas falsas, 20 errores automáticos y 53 revisiones. No hay una alternativa superior en todos los criterios.

Costos y elección provisional

Revisamos probabilidades OOF sobre 6.344 mensajes de entrenamiento, con 707 fraudes reales. Cada predicción proviene de una partición que no ajustó ese ejemplo. No se cambiaron configuraciones ni umbrales.

Resultado OOF	Naive Bayes	KNN
Fraudes mal derivados	49	27
Falsas alertas de fraude	88	340
Otros errores automáticos	219	126
Errores automáticos totales	356	493
Revisiones	33	201
Cobertura	99,48%	96,83%
Exactitud automática	94,36%	91,97%
Fraude perdido	6,93%	3,82%

A. Priorizar fraude: KNN pierde menos fraudes; conviene si esa reducción justifica más alertas falsas, revisiones y tiempo. Un fraude desviado y una alerta falsa tienen consecuencias distintas.

B. Reducir carga operativa: Naive Bayes tiene menos alertas falsas, errores automáticos y revisiones, y mayor exactitud automática. Es el supuesto elegido para esta entrega; aceptamos provisionalmente su mayor fraude perdido.

C. Equilibrar riesgo y capacidad: Cauce debe confirmar cuánto fraude tolera y qué volumen pueden atender Fraude y revisión. No conocemos costos económicos reales ni inventamos valores monetarios.

Sensibilidad hipotética sin doble conteo: la diferencia de costo KNN menos NB en OOF es (-22) × c_fraude + (252) × c_alerta + (-93) × c_otro + (168) × c_revisión. Cada peso corresponde a una categoría distinta. KNN se favorece si el resultado es negativo; NB si es positivo. El total de errores ya contiene las tres clases de error y no se suma otra vez.

En el lote de 1.000 mensajes del paso 12 al mayor tamaño, la predicción media fue 0,0275 s para NB y 0,1558 s para KNN. KNN busca vecinos; NB usa probabilidades aprendidas. Son tiempos de este equipo, no de atención al cliente ni de producción.

Los datos OOF ya participaron en la elección de parámetros y umbrales; pueden ser optimistas. Además, la prueba se consultó en la selección anterior. Esta revisión no es una confirmación independiente: se necesitan nuevos mensajes etiquetados.

Proyección y entrega

Para 6.500 mensajes diarios usamos la proporción de cortos 70/8000: 56,9 cortos y 6.443,1 aptos. A los aptos se aplican tasas de prueba; los cortos se suman una sola vez a revisión.

Mensajes esperados por día	Naive Bayes	KNN
Automáticos	6.410,6	6.195,3
Automáticos correctos	6.036,9	5.740,3
Automáticos incorrectos	373,8	455,0
Fraudes enviados a otro equipo	36,6	24,4
Falsas alertas de fraude	65,0	304,7
Revisión por incertidumbre (aptos)	32,5	247,8
Revisión por mensajes cortos	56,9	56,9
Revisión humana total	89,4	304,7

Como referencia, sobre la misma fracción apta la mesa proyecta 1.060,3 destinos incorrectos y 239,7 fraudes mal derivados. No se conoce el resultado de la atención de los cortos ni de las revisiones.

Son valores esperados si la distribución futura se parece a la muestra, no un día observado. Las alertas falsas y los fraudes perdidos ya están incluidos en los errores automáticos; no se suman como errores nuevos.

Errores revisados y mensajes nuevos

Analizamos diez de los 92 errores automáticos de Naive Bayes: hay consultas múltiples y pedidos sin contexto. Un caso etiquetado como préstamos denuncia acceso sin permiso; se propone revisar la anotación, conservando su etiqueta original. Los resúmenes del notebook están anonimizados.

Reentrenamos Naive Bayes con 7.930 históricos aptos. El CSV final tiene 2.040 filas y cinco columnas: 2.007 destinos automáticos y 33 revisiones, incluidas 15 por textos cortos. Conserva identificadores y orden originales; se entrega por separado y queda fuera del repositorio público. Se conservó un respaldo del CSV anterior de KNN.

Límites para decidir

La recomendación no demuestra aptitud para producción. Faltan metas oficiales, costos relativos, capacidad de revisión y riesgo tolerable confirmados por Cauce. Las probabilidades no se validaron como calibradas; los nuevos mensajes no tienen etiquetas para medir aciertos. Una confirmación independiente requiere datos etiquetados nuevos.