Clasificación automática de mensajes - Cauce

Para Laura Benítez
Andruszyszyn Emanuel - Quirós Juan
14 de octubre de 2026

Situación inicial y propuesta

Cauce recibe unos 6.500 mensajes por día y nueve personas los derivan. Un destino equivocado demora la atención; en fraude, ese tiempo puede impedir que se frene una operación sospechosa.

Desarrollamos un clasificador a partir del texto y comparamos Naive Bayes con KNN. La regla da prioridad a sospechas de fraude, deriva las clasificaciones con suficiente confianza y reserva las dudas para una persona. Los mensajes con menos de dos palabras siempre requieren revisión.

Comparación sobre los mismos mensajes

La evaluación reservada tiene 1.586 mensajes aptos. Los parámetros se eligieron en entrenamiento y los umbrales se fijaron con probabilidades fuera de muestra antes de evaluar estos registros. Los mensajes cortos no integran esta prueba.

Indicador	Mesa de entrada	Naive Bayes	KNN
Exactitud del clasificador	83,54%	93,88%	92,81%
F1 macro	0,8237	0,9346	0,9260
Cobertura de derivación	100,00%	99,50%	96,15%
Exactitud entre derivados	83,54%	94,17%	92,66%
Fraude perdido	33,52%	5,11%	3,41%

F1 macro combina precisión y recuperación de cada equipo y les da igual peso. Los dos primeros indicadores miden la clase predicha; los restantes miden destinos después de aplicar la regla. El 100% de cobertura de la mesa indica decisiones manuales ya realizadas, no automatización.

Recomendamos KNN para resolver el ejercicio: con prioridad al fraude, perdió 6 casos frente a 59 de la mesa. Naive Bayes tuvo mejores resultados generales y predijo más rápido; esa ventaja no reemplaza el criterio de riesgo elegido.

Los cinco indicadores de esta tabla son una propuesta descriptiva. Criterios de aceptación pendientes de confirmación: no se declara la solución lista para producción.

Fraude: resultados y costo de la prioridad

La regla usa P(fraude) >= 0,10 y confianza >= 0,60. Son valores provisionales. La selección mejoró a la mesa en las cinco particiones de entrenamiento y conservó esa mejora al probar umbrales vecinos; eso no garantiza el mismo comportamiento en otros datos.

Resultado en prueba	Mensajes
Fraudes reales	176
Fraudes enviados a Fraude por la regla	167
Fraudes enviados a revisión humana	3
Fraudes enviados automáticamente a otro equipo	6
Mensajes no fraudulentos enviados a Fraude	75

El clasificador directo reconoció 151 de los 176 fraudes: recall de 85,80% y precision de 94,97%. La regla recupera otros casos mediante la prioridad de fraude, pero también genera avisos falsos. Una derivación a revisión no se cuenta como fraude perdido.

Errores observados

Hubo 112 derivaciones automáticas incorrectas. Analizamos diez: aparecen consultas con dos intenciones, pedidos sin contexto y reclamos que comparten vocabulario con fraude. La prioridad puede mandar a Fraude una consulta legítima de tarjeta, transferencias o inversiones. Mejorar requiere revisar ejemplos y medir el costo de esos avisos.

También encontramos una posible inconsistencia: un texto que denuncia acceso sin autorización tiene como referencia préstamos e inversiones. Conservamos la etiqueta original y proponemos revisar la anotación con el responsable del caso; no se cambió para mejorar una métrica.

Límites de la recomendación

Faltan confirmar las metas oficiales, el riesgo de fraude tolerable y la capacidad de atención de los avisos y de la revisión humana. Las probabilidades no se validaron como estimaciones calibradas. La elección usa una muestra de prueba y no mide un servicio real ni tiempos de respuesta al cliente.

Impacto esperado y entrega

La proporción de mensajes cortos observada fue 70/8000. Para proyectar un día, estimamos 56,9 cortos y 6.443,1 mensajes aptos. Las tasas de prueba se aplican sólo a los aptos y los cortos se suman una vez a revisión.

Proyección del modelo elegido	Mensajes por día
Automáticos	6.195,3
Revisión humana total	304,7
Revisión por mensajes cortos	56,9
Automáticos correctos	5.740,3
Automáticos incorrectos	455,0
Fraudes enviados a otro equipo	24,4

Es una estimación, no un día observado. Supone que la distribución futura será parecida a la muestra. Los resultados de la revisión humana no están medidos y las cantidades decimales representan valores esperados.

Comparación sólo en mensajes aptos	KNN	Mesa
Derivaciones incorrectas por día	455,0	1.060,3
Fraudes enviados a otro equipo por día	24,4	239,7

Mensajes nuevos y próximos cuidados

Reentrenamos KNN con 7.930 históricos aptos, sin cambiar parámetros ni umbrales. Generamos 2.040 predicciones: 1.957 destinos automáticos y 83 revisiones, incluidas 15 por textos cortos. No hay etiquetas finales de esos mensajes para medir sus aciertos.

El CSV de entrega conserva una fila por mensaje y se mantiene local por sus identificadores. El notebook y este informe contienen resultados agregados. Antes de una implementación real conviene confirmar las metas, revisar las anotaciones y la privacidad, y evaluar nuevos mensajes con sus respuestas verificadas. La revisión humana sigue siendo parte de la propuesta.